Ejercicio de Machine Learning

Predicción de Enfermedad Cardiovascular

Objetivo

El objetivo de este ejercicio es aplicar y comparar dos modelos de aprendizaje automático para predecir la variable **output** (si un paciente tiene o no enfermedad cardiovascular) utilizando el conjunto de datos **heart_modified**.

Los modelos a evaluar son:

- Regresión Logística
- Random Forest

Descripción del Dataset

El dataset '**heart_modified'** contiene variables clínicas relacionadas con enfermedades cardiovasculares.

Columnas del dataset:

age: Edad del paciente
sex: Sexo del paciente (0 = masculino, 1 = femenino)
cp: Tipo de dolor en el pecho (chest pain type)
trestbps: Presión arterial en reposo
chol: Nivel de colesterol en sangre
fbs: Nivel de azúcar en sangre en ayunas (>120 mg/dl)
restecg: Resultados electrocardiográficos en reposo
thalach: Frecuencia cardíaca máxima alcanzada
exang: Angina inducida por ejercicio
oldpeak: Depresión del segmento ST inducida por ejercicio
slope: Pendiente del segmento ST durante el ejercicio
ca: Número de vasos coronarios principales coloreados por fluoroscopia
thal: Tipo de talasemia
output: Variable objetivo (1 = presencia de enfermedad cardiovascular, 0 = ausencia)

Instrucciones

1. Carga de datos

Cargar el dataset desde el archivo: *heart_modified.csv*

2. Comprobación de valores nulos (NaN)

- Revisar si existen valores nulos en el dataset.
- Rellenar la columna **age** con la **media redondeada** de la columna.
- Rellenar el resto de columnas con valores nulos utilizando la **moda**.
- Verificar que después de la imputación no queden valores nulos.

3. Comprobación de duplicados

- Revisar si existen registros duplicados.
- Eliminar los registros duplicados.
- Verificar que ya no existan registros repetidos.

4. Detección y eliminación de outliers

- Detectar posibles **outliers** utilizando el método **IQR (Interquartile Range)**.
- Eliminar los registros que contengan outliers.
- Verificar que tras el proceso no queden valores considerados outliers.

5. Reducción del DataFrame

Seleccionar únicamente las columnas necesarias para el análisis, por ejemplo:

- age
- chol
- sex
- output

6. Escalado de variables

El modelo de **Regresión Logística** utiliza coeficientes y puede verse afectado por diferencias en las escalas de las variables. Por ello, se debe aplicar **escalado de variables** al menos para este modelo.

7. Separación de variables

Separar el dataset en:

- Variables independientes (**X**): age, chol, sex
- Variable objetivo (**y**): output
- Dividir el dataset en: **80% datos de entrenamiento y 20% datos de prueba**

Modelos a Evaluar

8. Regresión Logística

Entrenar un modelo de **Logistic Regression** utilizando el conjunto de entrenamiento y evaluar su rendimiento en el conjunto de prueba.

9. Random Forest

Entrenar un modelo **Random Forest** utilizando el conjunto de entrenamiento.
Realizar una búsqueda de hiperparámetros mediante **GridSearchCV** para encontrar la mejor combinación de parámetros.

Parámetros a evaluar:

- n_estimators: [100, 200, 300]
- max_depth: [10, 20, 30]
- min_samples_split: [2, 5, 10]
- min_samples_leaf: [1, 2]

Utilizar **validación cruzada con cv = 5**.

10. Evaluación de modelos

Calcular la **precisión (accuracy)** de cada modelo utilizando el conjunto de prueba.
Comparar los resultados obtenidos y responder:

¿Qué modelo obtiene mejor rendimiento?

11. Predicción con nuevos datos

Realizar una predicción utilizando el modelo entrenado introduciendo nuevos valores para las variables utilizadas.